



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN
DIVISIÓN DE MATEMÁTICAS E INGENIERÍA
LICENCIATURA EN MATEMÁTICAS APLICADAS Y COMPUTACIÓN

Documentación del ETL

EQUIPO 1

BERNAL MARTÍNEZ LUIS EDUARDO	319012017
DÍAZ LÓPEZ ALAN FERNANDO	316166506
HERNÁNDEZ CASTILLO FERNANDA BERENICE	320200320
MARTÍNEZ HERNÁNDEZ IRVIN	320137833
MUÑOZ MARQUEZ ORTIZ ARTURO RAFAEL	320609792
MERA MONTIEL GONZALO SEBASTIÁN	423004890
ROSAS GONZÁLEZ MIGUEL ÁNGEL	423093814
VAN STEENBERGHE LUJÁN KRISTOFFER	319206463
VILCHIS LOPEZ VICTOR MANUEL	320090859

MATERIA:
MINERÍA DE DATOS

FECHA:
19 DE ABRIL DE 2026

SEMESTRE:
2026-2

Descripción del Proyecto

El presente documento detalla el proceso de ETL desarrollado por el Equipo 1 para el proyecto Smart Supply Chain, correspondiente al Examen 2 de la materia de Minería de datos.

El objetivo del proyecto es construir un ecosistema analítico end-to-end capaz de anticipar el comportamiento de la demanda y optimizar el almacenamiento en el sector retail, permitiendo a los usuarios tomar decisiones logísticas informadas a través de un dashboard interactivo de Business Intelligence.

Fuentes de Datos

Se utilizó el dataset público de Olist, una plataforma brasileña de e-commerce, compuesto por múltiples archivos CSV que presentan distintas entidades del negocio. A continuación se describen los datasets empleados:

Dataset	Descripción
olist (clientes/geolocalización)	Datos de clientes y coordenadas geográficas
orders y products	Pedidos realizados y catálogo de productos
payments	Métodos y montos de pago por pedido
product category	Categorías de productos con traducción al inglés
reviews	Reseñas y calificaciones de clientes
sellers	Información de vendedores registrados

Limpieza

Previo a la construcción del cubo de datos, se realizó la limpieza de los datasets en varios notebooks distintos, para luego consolidarlos en un único archivo (ETL_ProyectoMD.ipynb). A continuación se describen las decisiones tomadas por dataset:

- Olist
 - Conversión de ciertos datos para la facilitación de su lectura general
 - Capitalización de ciudades
 - Eliminación de duplicados y normalización de ciudades con acentos inconsistentes (são paulo vs sao paulo)
- Products y Orders

- Categorías nulas: Se imputaron 610 valores nulos en `product_category_name` con la etiqueta 'Sin Categoría'.
- Formato de texto: Se reemplazaron guiones bajos por espacios y se aplicó Title Case para estandarizar el texto (ej. `esporte_lazer` → `Esporte Lazer`).
- Variables numéricas: Las columnas de dimensiones, peso y fotografías se imputaron con la mediana de cada columna para evitar distorsiones por valores atípicos.
- Estatus del pedido: Se normalizó el campo `order_status` eliminando espacios y aplicando capitalización consistente.
- Fechas: Las 5 columnas de timestamps se convirtieron de texto a formato `datetime64`. Los nulos en fechas de entrega se conservaron intencionalmente para pedidos cancelados.
- Feature Engineering: Se creó la columna `fecha_compra_dia` extrayendo únicamente la fecha del timestamp de compra, diseñada para servir como llave de integración con fuentes exógenas.
-
- Payments
 - Se verificó la integridad de los montos de pago y su correspondencia con los pedidos en el dataset de ítems
- Product Category
 - Se estandarizó el nombre de las categorías y se integró la traducción al inglés disponible en el dataset.
- Reviews
 - Se trató la información de reseñas y calificaciones asegurando consistencia en los identificadores de pedido
- Sellers
 - Se verificó la unicidad de los identificadores de vendedor y se estandarizó la información geográfica

ETL

El archivo `ETL_ProyectoMD.ipynb` contiene el proceso completo de transformación de los datos limpios (OLTP) a estructuras analíticas (OLAP). El proceso se divide en tres etapas principales:

Construcción del Cubo y Sábana

A partir de los CSVs limpios se construyeron las siguientes estructuras:

Tabla	Tipo	Descripción
<code>dim_tiempo</code>	Dimensión	Fechas de compra desglosadas (año, mes, día, etc.)

dim_cliente	Dimensión	Información única por cliente
dim_geografia_cliente	Dimensión	Coordenadas y estado del cliente
dim_producto	Dimensión	Catálogo de productos con categoría
dim_vendedor	Dimensión	Información de vendedores
fact_ventas	Tabla de Hechos	Granularidad: order_id + order_item_id. Incluye precio, flete y valor de pago proporcional
tad_ventas	Sábana	Vista plana que combina fact_ventas con todas sus dimensiones
tad_pedidos	Sábana	Vista plana a nivel de pedido para análisis logístico

Validaciones

Se realizaron las siguientes pruebas de calidad sobre las tablas generadas:

- Unicidad de llaves primarias en todas las dimensiones (100% único en todos los casos).
- Granularidad de fact_ventas: verificación de que order_id + order_item_id no genere duplicados.
- Integridad referencial: proporción de llaves foráneas de fact_ventas que existen en sus dimensiones correspondientes (valor cercano a 1.0 en todos los casos).
- Nulos críticos: ausencia de nulos en campos clave como order_id, product_id, seller_id, fecha_key y métricas monetarias.
- Consistencia de métricas: la suma de price y freight_value en fact_ventas coincide exactamente con los valores en la tabla fuente de ítems. El payment_value fue distribuido proporcionalmente por ítem.


Carga de BigQuery

Las tablas sábana (tad_ventas y tad_pedidos) fueron cargadas a la base de datos del proyecto en Google BigQuery utilizando la librería google-cloud-bigquery. La autenticación se realizó mediante un archivo de credenciales JSON proporcionado por el profesor. Se utilizó la política WRITE_TRUNCATE para sobrescribir la tabla en cada carga.

Dashboard

Con base en las tablas cargadas en BigQuery, se construyó un dashboard en Looker Studio. El dashboard permite explorar el comportamiento de ventas, pedidos, categorías de productos y desempeño de vendedores.

[Liga al Dashboard](#)



Logística y Cumplimiento

Selecciona un periodo

Concentrado en tiempos, retrasos y precisión logística

Días adelantados promedio

11,31


Días promedio estimados de entrega

23,4


Días promedio reales de entrega

12,09


Días reales de entrega



Clasificación de entrega



Retraso por estado



Pedidos con mayor retraso

	Orden	Estado del cliente	Status de orden	Día real de entrega	Día estimado de entrega	Días de retraso de entrega
1.	1b3190b2dfa9d789e1f14c05b647a14a	RJ	delivered	208	19	188
2.	ca07593549f1816d26a572e06dc1eab6	ES	delivered	209	28	181
3.	47b40429ed8cce3aee9199792275433f	SP	delivered	191	15	175
4.	2fe324feb1907e3ea3f2aa9650869fa5	SP	delivered	189	22	167
5.	285ab9426d6982034523a855f55a885e	SE	delivered	194	28	166
6.	440d0d17af552815d15a9e41abe49359	PA	delivered	195	30	165
7.	c27815f7e3dd0b926b58552628481575	MG	delivered	187	25	162
8.	0f4519c5f1c541ddec9f21b3bdd533a	PI	delivered	194	32	161
9.	d24e8541128cea179a11a65176e0a96f	SP	delivered	175	13	161
10.	2d7561026d542c8dbd8f0daeaddf67a43	SE	delivered	188	28	159
11.	2fb597c2f772eca01b1f5c561bf6cc7b	PI	delivered	194	39	155

1 - 100 / 99441

Experiencia Del Cliente

Satisfacción del cliente


Selecciona un periodo

Calificación promedio
4,09


% buenas reseñas
76,46 %

% malas reseñas
14,53 %


Calificación por orden



Calificación promedio por tipo de pago



Calificación promedio por días de retraso



Malas reseñas

	Orden	Estado de Cliente	Tipo de pago	Días de retraso de entre...	Calificación
1.	1b3190b2dfa9d789e1f14c05b647a14a	RJ	credit_card	188	2
2.	47b40429ed8cce3aee9199792275433f	SP	credit_card	175	1
3.	2fe324feb907e3ea3f2aa9650869fa5	SP	boleto	167	1
4.	285ab9426d6982034523a855f55a885e	SE	credit_card	166	1
5.	440d0d17af552815d15a9e41abe49359	PA	credit_card	165	1
6.	2ba1366baecad3c3536f27546d129017	GO	boleto	152	1
7.	6e6527028de694ccade37f5a15a6d84a	RJ	credit_card	143	1
8.	df6d8b7768a047c2981bae0a24afb01	CE	credit_card	132	1
9.	031e7d4e559a1bf08e71a419aa998d0a	PE	voucher	123	1
10.	4f39a94d6e474819d898d6df7d394996	GO	boleto	112	2

1 - 100 / 14449 < >

Productos y Categorías

Productos y categorías que genera el negocio


Selecciona un periodo

Seleccione Código del Estado

Rango De Precio

Total De Productos Vendidos
112.650

Ingreso Promedio Por Ítem
140,67



Productos Con Mayor Ingreso

	ID Producto	ID Estado	Valor de Pago	Precio
1.	bb50f2e236e5eea0100680137654686c	f7ba60f8c3f99e7ee4042fdef03b70c4	67.305,09	327,62
2.	d1c427060a0f73f6b889a5c7c61f2ac4	a1043baf4d71dff536d0c462352be...	60.460,85	137,65
3.	6cdd53843498f92890544667809f1595	ccc4bbb5f32a6ab2b7066a4130f11...	58.653,9	350,83
4.	99a4788cb24856965c36a24e339b6058	4a3ca9315b744ce9f8e937436149...	50.995,18	88,21
5.	d6160fb7873f184099d9bc95e30376af	53243585a1d6dc2643021fd1853d...	50.326,18	1.397,12
6.	3dd2a17168ec895c781a9191c1e95ad7	de722cd6dad950a92b7d4f82673f8...	48.055,87	149,94
7.	aca2eb7d00ea1a7b8ebd4e68314663af	955fee9216a65b617aa5c0531780...	44.787,89	71,36
8.	5f504b3a1c75b73d6151be81eb05bdc9	834f3294fba9f932f56edc879193f925	41.437,81	598,95
9.	422879e10f46682990de24d770e7f83d	1f50f920176fa81dab994f90235231...	34.353,43	54,91
10.	f1c7f353075ce59d8a6f3cf58f419c9c	37be5a7c751166fbc5f8ccba4119e...	33.295,93	194,79

1 - 10 / 34448 < >


Seller Y Oportunidades

Selecciona un periodo


Oportunidades de mejora

Número de vendedores
3.095


Mejores sellers por ingreso




Sellers por volumen de productos vendidos



Cantidad de sellers por estado



Ingreso vs Costo por seller



Sellers prioritarios

	Seller	Estado del seller	Cantidad de productos	Ingresos ▾	Costo	Precio
1.	4869f7a5dfa277a7...	SP	1.156	250.012,51	17,45	198,51
2.	7c67e1448b009e...	SP	1.364	238.802,46	37,84	137,77
3.	4a3ca9315b744ce...	SP	1.987	236.515,84	17,65	100,89
4.	53243585a1d8dc2...	BA	410	235.856,69	31,9	543,36
5.	fa1c13f2614d7b5c...	SP	586	203.811,38	17,14	331,13
6.	da8622b14eb17ae...	SP	1.551	184.847,1	18,09	103,31
7.	7e93a43ef30c4f03...	SP	340	182.245,58	18,59	518,92
8.	1025f0e2d44d704...	SP	1.428	172.518,12	23,73	97,32
9.	7a67c85e85bb2ce...	SP	1.171	162.804,12	17,85	121,05
10.	955fee921ba85b8...	SP	1.499	160.909,84	16,97	90,17

1 - 100 / 3095 < >